Métodos Iterativos para Sistemas Lineales

Método de Jacobi y Método de Gauss–Seidel

Diego Valencia

Universidad Mariana

11 de marzo de 2026

Contenido

1. Introducción
2. Formulación general
3. Método de Gauss–Seidel
4. Convergencia: ¿cuándo funcionan?
5. Ejemplo guiado (a mano)
6. Comparación y conclusiones
7. Ejercicios
8. Códigos

¿Por qué métodos iterativos?

¿Cuándo conviene resolver $A\mathbf{x} = \mathbf{b}$ de forma iterativa?

Motivación

Contexto

Resolver un sistema lineal $A\mathbf{x} = \mathbf{b}$ es una tarea central en ingeniería. En muchos casos, los métodos directos (Gauss, LU) pueden ser costosos o poco convenientes.

- Sistemas **grandes** (miles o millones de incógnitas).
- Matrices **dispersas** (sparse): muchos ceros.
- Soluciones aproximadas son aceptables (tolerancia).
- Problemas repetitivos (múltiples $\mathbf{b}$ con el mismo A).

Idea clave

Construir una sucesión $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \ldots$ que converja a la solución.

Ejemplos en Ingeniería Civil

- **Estructuras**: métodos matriciales (rigidez) $\Rightarrow$ sistemas grandes y dispersos.
- **Hidráulica/CFD**: discretización (volúmenes finitos, diferencias finitas) $\Rightarrow$ A sparse.
- **Geotecnia**: elementos finitos para deformaciones y consolidación.
- **Redes**: caudales/presiones en redes de tuberías (iteraciones acopladas).

Sistema lineal y notación

Problema

$$A\mathbf{x} = \mathbf{b}, \qquad A \in \mathbb{R}^{n\times n},\ \mathbf{x} \in \mathbb{R}^n,\ \mathbf{b} \in \mathbb{R}^n.$$

Criterios de parada (prácticos)

Tres opciones comunes

- **Error relativo aproximado**:

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k+1)}\|} < \text{tol}$$

- **Residual**:

$$\mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}, \qquad \frac{\|\mathbf{r}^{(k)}\|}{\|\mathbf{b}\|} < \text{tol}$$

- **Máximo de iteraciones**: $k \leq k_{\text{máx}}$.

Recomendación en clase

Usar el **residual** como indicador principal (mide qué tan bien satisface el sistema).

Idea del método de Gauss–Seidel

Actualización "en cascada"

Gauss–Seidel usa valores **más recientes disponibles** dentro de la misma iteración:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij} x_j^{(k+1)} - \sum_{j>i} a_{ij} x_j^{(k)} \right)$$

- Suele converger más rápido que Jacobi (en la práctica).
- No es tan paralelizable como Jacobi.
- Se parece a "ir sustituyendo" de inmediato lo que ya calculaste.

Condiciones típicas de convergencia

Suficientes (muy usadas en curso)

- **Dominancia diagonal estricta** por filas:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i$$

- **Matriz simétrica definida positiva (SPD)**:

$$A = A^T, \qquad \mathbf{x}^T A \mathbf{x} > 0 \;\; \forall \mathbf{x} \neq \mathbf{0}$$

Comentarios

- Si A es diagonalmente dominante estricta: **GS converge**.
- Si A es SPD: **GS converge** (y usualmente muy bien).

¿Y si no converge? (ideas prácticas)

- Reordenar ecuaciones/variables para favorecer dominancia diagonal.
- Escalamiento (normalización) del sistema.

entre otros.

En clase

Primero verificar dominancia diagonal y luego aplicar Jacobi/GS con criterio de parada por residual.

Sistema de ejemplo (y residual)

Problema

Resolver aproximadamente el sistema:

$$\begin{cases} 10x_1 - x_2 + 2x_3 = 6 \\ -x_1 + 11x_2 - x_3 = 25 \\ 2x_1 - x_2 + 10x_3 = -11 \end{cases}$$

- La matriz es diagonalmente dominante estricta:

$$10 > 1 + 2, \quad 11 > 1 + 1, \quad 10 > 2 + 1$$

- Por tanto, **Gauss–Seidel debería converger**.
- Tomar $\mathbf{x}^{(0)} = (0, 0, 0)^T$.

Residual (medida del error del sistema)

$$r^{(k)} = b - Ax^{(k)}, \qquad \|r^{(k)}\|_\infty = \max_i |r_i^{(k)}|$$

Gauss–Seidel: iteración 1 (con residual)

Reglas (GS)

$$x_1^{(k+1)} = \frac{1}{10}\left(6 + x_2^{(k)} - 2x_3^{(k)}\right)$$

$$x_2^{(k+1)} = \frac{1}{11}\left(25 + x_1^{(k+1)} + x_3^{(k)}\right)$$

$$x_3^{(k+1)} = \frac{1}{10}\left(-11 - 2x_1^{(k+1)} + x_2^{(k+1)}\right)$$

Iteración 1 (desde $\mathbf{x}^{(0)} = \mathbf{0}$)

$$x_1^{(1)} = \tfrac{1}{10}(6 + 0 - 2 \cdot 0) = 0{,}6$$

$$x_2^{(1)} = \tfrac{1}{11}(25 + x_1^{(1)} + 0) = \tfrac{1}{11}(25{,}6) = 2{,}3273$$

$$x_3^{(1)} = \tfrac{1}{10}\left(-11 - 2x_1^{(1)} + x_2^{(1)}\right) = \tfrac{1}{10}(-11 - 1{,}2 + 2{,}3273) = -0{,}9873$$

Residual en $k = 1$: $r^{(1)} = b - Ax^{(1)}$

$$r_1^{(1)} = 6 - \big(10(0{,}6) - 2{,}3273 + 2(-0{,}9873)\big) = 6 - (1{,}6981) = 4{,}3019$$

$$r_2^{(1)} = 25 - \big(-0{,}6 + 11(2{,}3273) - (-0{,}9873)\big) = 25 - (26{,}1876) = -1{,}1876$$

$$r_3^{(1)} = -11 - \big(2(0{,}6) - 2{,}3273 + 10(-0{,}9873)\big) = -11 - (-10{,}9999) \approx -0{,}0001$$

Gauss–Seidel: iteración 2 (con residual)

Iteración 2

$$x_1^{(2)} = \tfrac{1}{10}\left(6 + x_2^{(1)} - 2x_3^{(1)}\right) = \tfrac{1}{10}\left(6 + 2{,}3273 - 2(-0{,}9873)\right) = 1{,}0302$$

$$x_2^{(2)} = \tfrac{1}{11}\left(25 + x_1^{(2)} + x_3^{(1)}\right) = \tfrac{1}{11}(25 + 1{,}0302 - 0{,}9873) = 2{,}2766$$

$$x_3^{(2)} = \tfrac{1}{10}\left(-11 - 2x_1^{(2)} + x_2^{(2)}\right) = \tfrac{1}{10}\left(-11 - 2(1{,}0302) + 2{,}2766\right) = -1{,}0784$$

Residual en $k = 2$: $r^{(2)} = b - Ax^{(2)}$

$$r_1^{(2)} = 6 - \big(10(1{,}0302) - 2{,}2766 + 2(-1{,}0784)\big) = 6 - (5{,}8698) = 0{,}1302$$

$$r_2^{(2)} = 25 - \big(-1{,}0302 + 11(2{,}2766) - (-1{,}0784)\big) = 25 - (25{,}1508) = -0{,}1508$$

$$r_3^{(2)} = -11 - \big(2(1{,}0302) - 2{,}2766 + 10(-1{,}0784)\big) = -11 - (-11{,}0000) \approx 0{,}0000$$

$$\|r^{(2)}\|_\infty = \text{máx}\{0{,}1302, 0{,}1508, 0{,}0000\} = 0{,}1508$$

Observación

GS usa valores recién calculados y reduce el residual rápidamente:

$$\|r^{(0)}\|_\infty = 25 \;\rightarrow\; \|r^{(1)}\|_\infty \approx 4{,}3019 \;\rightarrow\; \|r^{(2)}\|_\infty \approx 0{,}1508$$

Ejemplo guiado: sistema y criterio

Sistema

$$\begin{cases} 10x_1 - x_2 + 2x_3 = 6 \\ -x_1 + 11x_2 - x_3 = 25 \\ 2x_1 - x_2 + 10x_3 = -11 \end{cases} \qquad A = \begin{bmatrix} 10 & -1 & 2 \\ -1 & 11 & -1 \\ 2 & -1 & 10 \end{bmatrix}, \; b = \begin{bmatrix} 6 \\ 25 \\ -11 \end{bmatrix}$$

Residual (indicador de calidad)

$$r^{(k)} = b - Ax^{(k)}, \qquad \|r^{(k)}\|_\infty = \max_i |r_i^{(k)}|$$

- Semilla: $x^{(0)} = (0, 0, 0)^T$.
- La matriz es diagonalmente dominante $\Rightarrow$ se espera convergencia.

Gauss–Seidel: tabla de iteraciones (con residual)

Gauss–Seidel (valores calculados y redondeados)

$$x_1^{(k+1)} = \frac{1}{10}(6 + x_2^{(k)} - 2x_3^{(k)}),\ x_2^{(k+1)} = \frac{1}{11}(25 + x_1^{(k+1)} + x_3^{(k)}),\ x_3^{(k+1)} = \frac{1}{10}(-11 - 2x_1^{(k+1)} + x_2^{(k+1)})$$

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\|r^{(k)}\|_\infty$
0	0.00000	0.00000	0.00000	2.50000e+01
1	0.60000	2.32727	-0.98727	4.30182e+00
2	1.03018	2.27663	-1.07837	1.31557e-01
3	1.04334	2.26954	-1.08171	3.33973e-03
4	1.04330	2.26923	-1.08174	2.62104e-04
5	1.04327	2.26923	-1.08173	1.40341e-05

Observación: Gauss–Seidel reduce el residual más rápido (usa valores actualizados dentro de la iteración).

Comparación rápida del ejemplo

Comparación por residual

- En $k = 1$: Jacobi $\|r^{(1)}\|_\infty \approx 4{,}4$ vs. GS $\approx 4{,}3$.
- En $k = 3$: Jacobi $\approx 0{,}2384$ vs. GS $\approx 0{,}00334$.

Conclusión del ejemplo

Con la misma semilla y el mismo sistema, **Gauss–Seidel** tiende a converger en menos iteraciones.

Jacobi vs Gauss–Seidel

Aspecto	**Jacobi**	**Gauss–Seidel**
Actualización	simultánea (con $\mathbf{x}^{(k)}$)	secuencial (usa valores nuevos)
Velocidad típica	más lenta	más rápida
Paralelización	alta	baja/moderada
Implementación	simple	simple
Convergencia (DD estricta)	sí	sí

Cuadro: Comparación cualitativa

Conclusiones

Mensajes clave

- Los métodos iterativos construyen $\mathbf{x}^{(k)}$ hasta cumplir tolerancia.
- Jacobi es simple y paralelizable, pero suele ser más lento.
- Gauss–Seidel aprovecha actualizaciones inmediatas y suele converger más rápido.
- La convergencia se facilita si A es **diagonalmente dominante** o **SPD**.
- En práctica: monitorear el **residual** y usar $k_{\text{máx}}$.

Ejercicios propuestos

$$\begin{cases} 8x_1 + x_2 - x_3 = 7 \\ 2x_1 + 10x_2 + x_3 = -8 \\ -x_1 + x_2 + 5x_3 = 6 \end{cases}$$

1. Aplique **Gauss–Seidel** al sistema anterior (2 iteraciones), iniciando con $\mathbf{x}^{(0)} = \mathbf{0}$.
2. Para el sistema del ejemplo guiado, calcule el residual $\mathbf{r}^{(2)} = \mathbf{b} - A\mathbf{x}^{(2)}$ para GS.
3. Investigue: ¿qué es el método SOR y cómo se relaciona con Gauss–Seidel?

Python: Método de Gauss–Seidel

Objetivo: resolver $A\mathbf{x} = \mathbf{b}$ por Gauss–Seidel (actualización secuencial).

```
import numpy as np

def gauss_seidel(A, b, x0=None, tol=1e-8, kmax=200):
    A = np.array(A, dtype=float)
    b = np.array(b, dtype=float)
    n = len(b)

    x = np.zeros(n) if x0 is None else np.array(x0, dtype=float)

    for k in range(kmax):
        x_old = x.copy()

        for i in range(n):
            s1 = np.dot(A[i, :i], x[:i])       # usa x^{(k+1)} ya actualizado
            s2 = np.dot(A[i, i+1:], x_old[i+1:])  # usa x^{(k)} anterior
            x[i] = (b[i] - s1 - s2) / A[i, i]

        r = b - A @ x
        if np.linalg.norm(r, ord=np.inf) / np.linalg.norm(b, ord=np.inf) < tol:
            return x, k+1

    return x, kmax

A = [[10, -1,  2],
     [-1, 11, -1],
     [ 2, -1, 10]]
b = [6, 25, -11]

x_aprox, it = gauss_seidel(A, b, x0=[0,0,0], tol=1e-10, kmax=500)
print("x =", x_aprox, " iteraciones =", it)
```

Comparación numérica sugerida (actividad)

Actividad en clase / tarea

Para el sistema del ejemplo, ejecute Jacobi y Gauss–Seidel con:

$$\text{tol} = 10^{-6}, \quad k_{\text{máx}} = 200, \quad \mathbf{x}^{(0)} = \mathbf{0}$$

- Reporte: número de iteraciones, solución aproximada y norma del residual final.
- Compare: ¿cuál converge en menos iteraciones?
- Discuta: ¿qué ocurre si cambia $\mathbf{x}^{(0)}$?

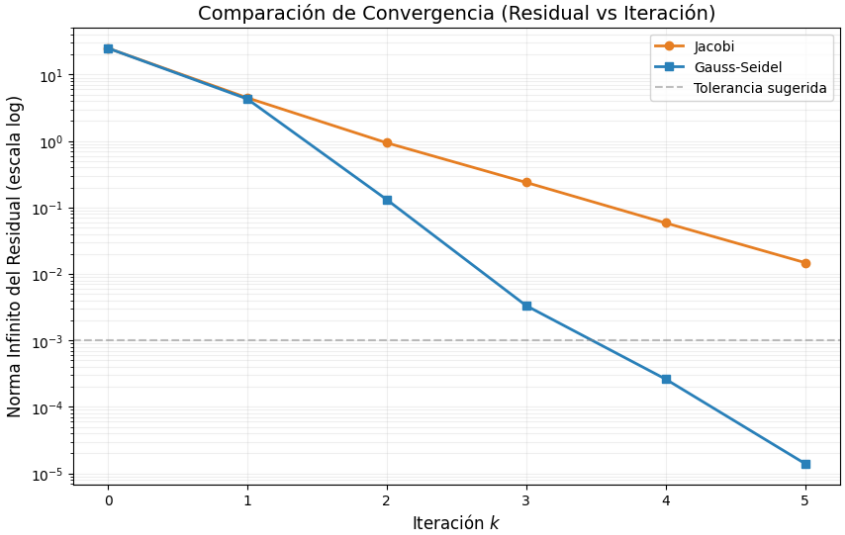

¡Gracias!

¿Preguntas?