# Regresión por Mínimos Cuadrados

## Aproximación Polinomial

PhD. Diego Valencia

Universidad Mariana
Ingeniería Civil
Curso: Métodos Numéricos

10 de marzo de 2026

## Aproximación polinomial por mínimos cuadrados

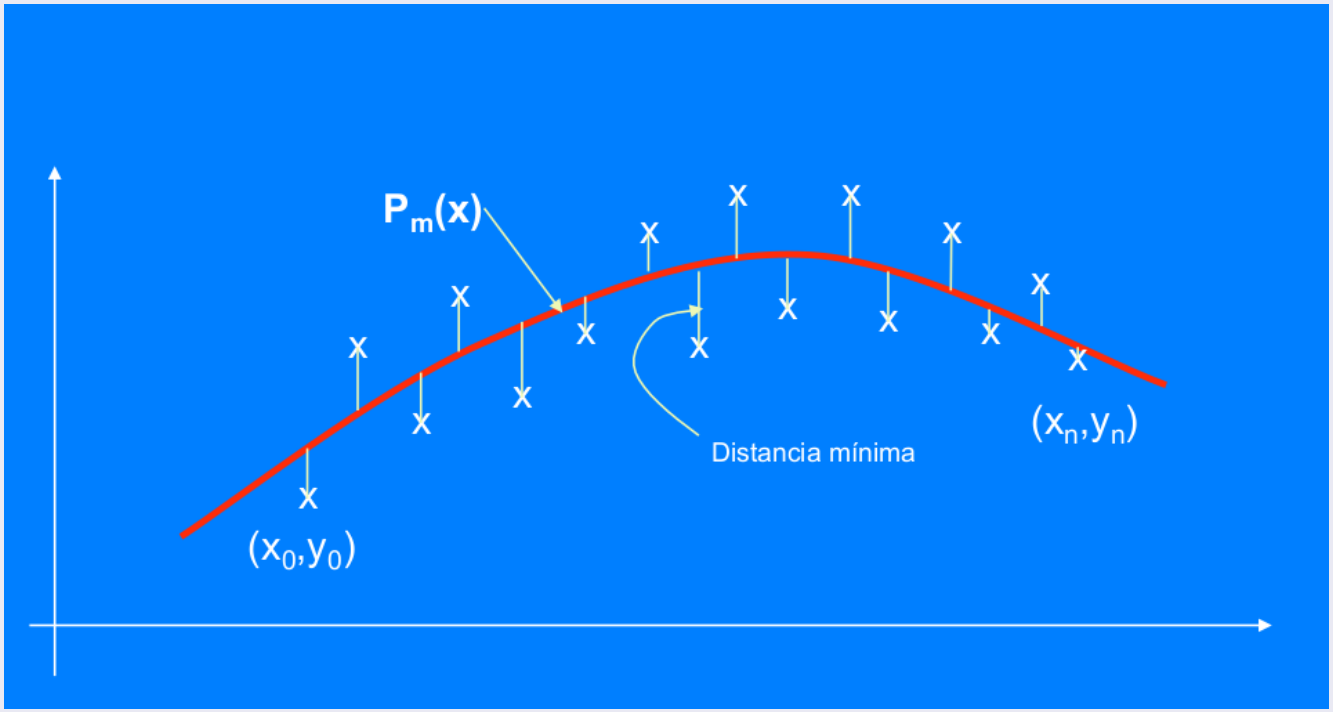


**Objetivo:** Obtener un polinomio o función que relacione $x$ e $y$

**Aproximación polinomial por mínimos cuadrados**

**El concepto**

- Forma de aproximar una función $g(x)$ a partir de datos $f(x)$.
- Nos proporciona información acerca de las relaciones existentes entre $x$ e $y$.
- Suaviza la curva formada por un conjunto de datos y elimina (en algún grado) errores de observador, medición, registro, transmisión y conversión.

## Modelo

Se tiene una secuencia de datos dada por $n$ puntos $(x_i, y_i)$. También se tiene un polinomio de grado $m$ con $m < n$:

$$P_m(x) = a_0x^0 + a_1x^1 + a_2x^2 + \cdots + a_mx^m = \sum_{j=0}^{m} a_jx^j.$$

# Como los puntos $(x_i, y_i)$ son datos...

Como los puntos $(x_i, y_i)$ son datos, se evalúan los cuadrados de los residuos para obtener los coeficientes del polinomio $P(x)$ de la forma:

## Función objetivo

$$Q = \sum_{i=1}^{n} r_i^2 = \sum_{i=1}^{n} \left[P_m(x_i) - y_i\right]^2 \qquad \text{(sea mínima)}$$

## Caso $m = 2$

$$P_2(x) = a_0 + a_1 x + a_2 x^2$$

$$Q = \sum_{i=1}^{n} \left[y_i - \left(a_0 + a_1 x_i + a_2 x_i^2\right)\right]^2$$

## Condición de mínimo

$$\frac{\partial Q}{\partial a_0} = 0, \qquad \frac{\partial Q}{\partial a_1} = 0, \qquad \frac{\partial Q}{\partial a_2} = 0.$$

# Ecuaciones normales para $m = 2$

Partiendo de

$$Q = \sum_{i=1}^{n} \left[ y_i - \left( a_0 + a_1 x_i + a_2 x_i^2 \right) \right]^2 ,$$

se obtiene:

## Derivadas (condición de mínimo)

$$\frac{\partial Q}{\partial a_0} = -2 \sum_{i=1}^{n} \left[ y_i - \left( a_0 + a_1 x_i + a_2 x_i^2 \right) \right] = 0$$

$$\frac{\partial Q}{\partial a_1} = -2 \sum_{i=1}^{n} x_i \left[ y_i - \left( a_0 + a_1 x_i + a_2 x_i^2 \right) \right] = 0$$

$$\frac{\partial Q}{\partial a_2} = -2 \sum_{i=1}^{n} x_i^2 \left[ y_i - \left( a_0 + a_1 x_i + a_2 x_i^2 \right) \right] = 0$$

# Sistema (forma expandida y matricial) para $m = 2$

## Forma expandida

$$\sum_{i=1}^{n} y_i = \sum_{i=1}^{n} a_0 + \sum_{i=1}^{n} a_1 x_i + \sum_{i=1}^{n} a_2 x_i^2$$

$$\sum_{i=1}^{n} x_i y_i = \sum_{i=1}^{n} a_0 x_i + \sum_{i=1}^{n} a_1 x_i^2 + \sum_{i=1}^{n} a_2 x_i^3$$

$$\sum_{i=1}^{n} x_i^2 y_i = \sum_{i=1}^{n} a_0 x_i^2 + \sum_{i=1}^{n} a_1 x_i^3 + \sum_{i=1}^{n} a_2 x_i^4$$

## Forma matricial

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{Bmatrix}$$

# CASO GENERAL

Modelo

$$P_m(x) = \sum_{j=0}^{m} a_j x^j$$

## Sistema de ecuaciones normales

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \cdots & \sum x_i^m \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \cdots & \sum x_i^{m+1} \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \cdots & \sum x_i^{m+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^{m-1} & \sum x_i^m & \sum x_i^{m+1} & \cdots & \sum x_i^{2m} \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_m \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \\ \vdots \\ \sum x_i^m y_i \end{Bmatrix}$$

## Forma matricial compacta

$$[C]\{a\} = \{b\}$$

$$\{a\} = [C]^{-1}\{b\}$$

# Ejemplo: secuencia de datos

## Datos

| $X$ | 0,0 | 1,0 | 2,0 | 3,0 | 4,0 | 5,0 | 6,0 | 7,0 |
|---|---|---|---|---|---|---|---|---|
| $Y$ | 1,7 | 0,3 | 5,6 | 7,8 | 10,0 | 11,0 | 12,0 | 14,0 |

## Gráfica

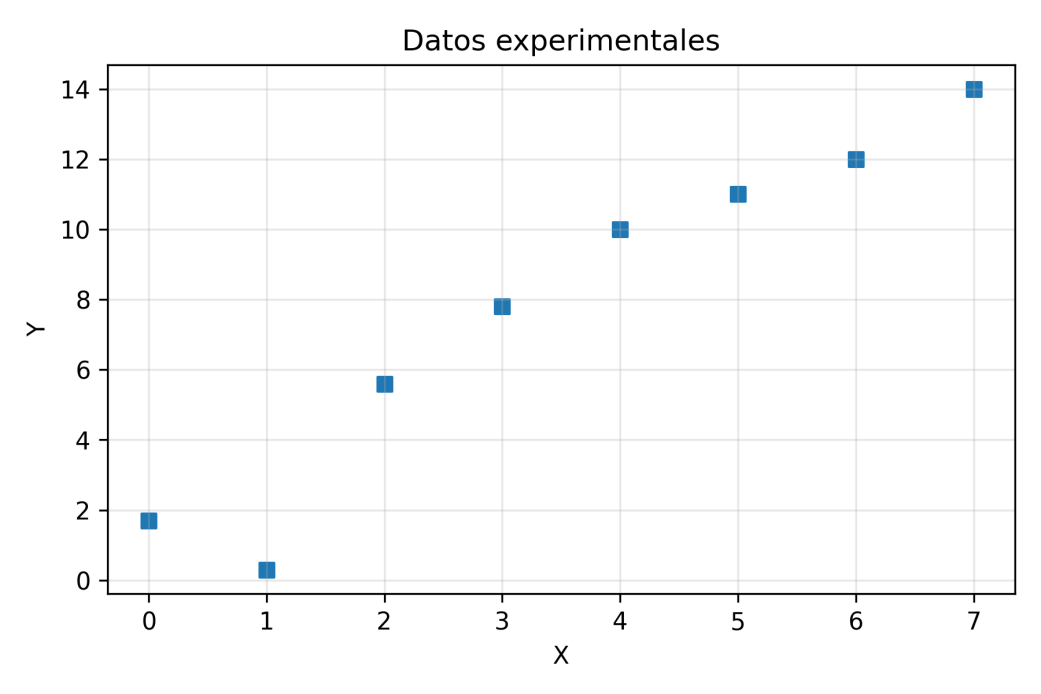

# Regresión lineal

## Modelo

$$P_1(x) = a_0 + a_1 x$$

## Función objetivo

$$Q = \sum_{i=1}^{n} [y_i - (a_0 + a_1 x_i)]^2$$

## Ecuaciones normales (lineal)

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \end{Bmatrix}$$

$$\begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix} = \begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}^{-1} \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \end{Bmatrix}$$

## Figura

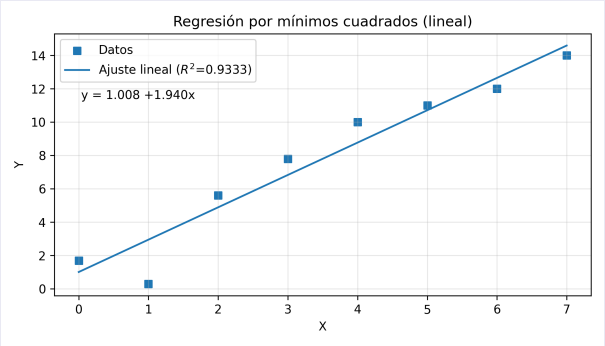

# Se prueba un polinomio de 2° ($m = 2$): $P_2(x) = a_0 + a_1 x + a_2 x^2$

## Forma matricial

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{Bmatrix}$$

## Sumatorias (del ejemplo)

$$n = 8, \quad \sum x_i = 28, \quad \sum x_i^2 = 140, \quad \sum x_i^3 = 784, \quad \sum x_i^4 = 4676$$

$$\sum y_i = 61{,}4, \quad \sum x_i y_i = 292{,}9, \quad \sum x_i^2 y_i = 1597$$

## Sistema normal

$$\begin{bmatrix} 8 & 28 & 140 \\ 28 & 140 & 784 \\ 140 & 784 & 4676 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} 61{,}4 \\ 292{,}9 \\ 1597 \end{Bmatrix}$$

## Figura

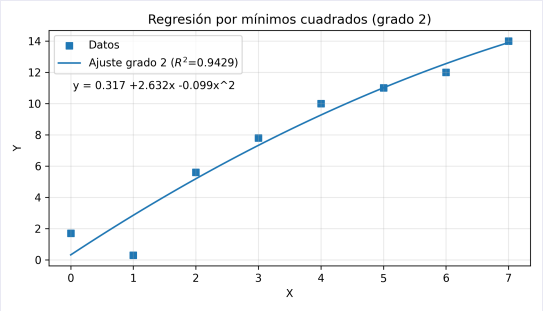


## Resultado

$$P(x) = 0{,}115 + 2{,}879x - 0{,}145x^2$$

# Se prueba un polinomio de 3° ($m = 3$)

## Modelo

$$P_3(x) = a_0 + a_1 x + a_2 x^2 + a_3 x^3$$

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \sum x_i^5 \\ \sum x_i^3 & \sum x_i^4 & \sum x_i^5 & \sum x_i^6 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \\ a_3 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \\ \sum x_i^3 y_i \end{Bmatrix}$$

## Sistema normal

$$\begin{bmatrix} 8 & 28 & 140 & 784 \\ 28 & 140 & 784 & 4676 \\ 140 & 784 & 4676 & 29008 \\ 784 & 4676 & 29008 & 184820 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \\ a_3 \end{Bmatrix} = \begin{Bmatrix} 61{,}4 \\ 292{,}9 \\ 1597 \\ 9321{,}7 \end{Bmatrix}$$

## Resultado

$$P(x) = 0{,}446 + 1{,}519x + 0{,}408x^2 - 0{,}054x^3$$

## Figura

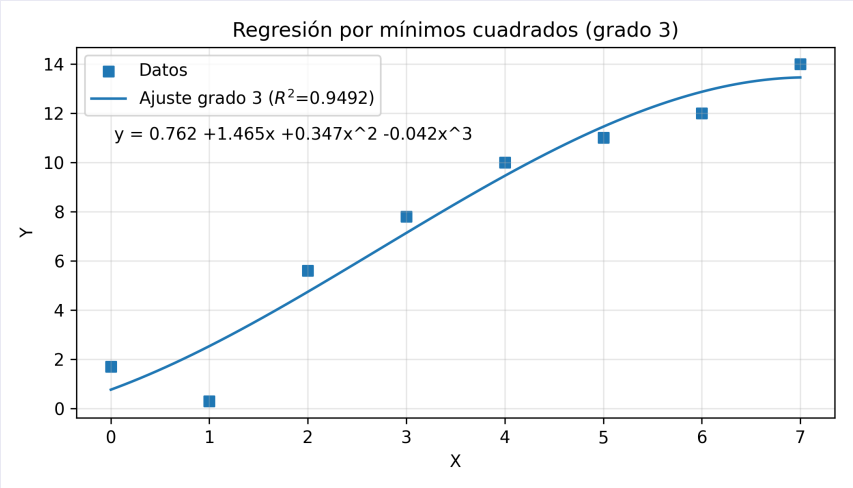

# ¿Cuál de las soluciones es mejor?

## Criterio intuitivo

La curva que mejor representa el comportamiento de los datos es aquella para la cual la suma de las distancias al cuadrado es lo más cercana a cero:

$$Q = \sum_{i=1}^{n} r_i^2 = \sum_{i=1}^{n} [P_m(x_i) - y_i]^2 .$$

## $R^2$ (coeficiente de correlación)

$$R^2 = 1 - \frac{\sum_{i=1}^{n} [P_m(x_i) - y_i]^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}$$

## Valores reportados

$$R^2_{\text{lineal}} = 0{,}9333,$$

$$R^2_{\text{cuadrática}} = 0{,}9426,$$

$$R^2_{\text{cúbica}} = 0{,}9492$$

## Figura

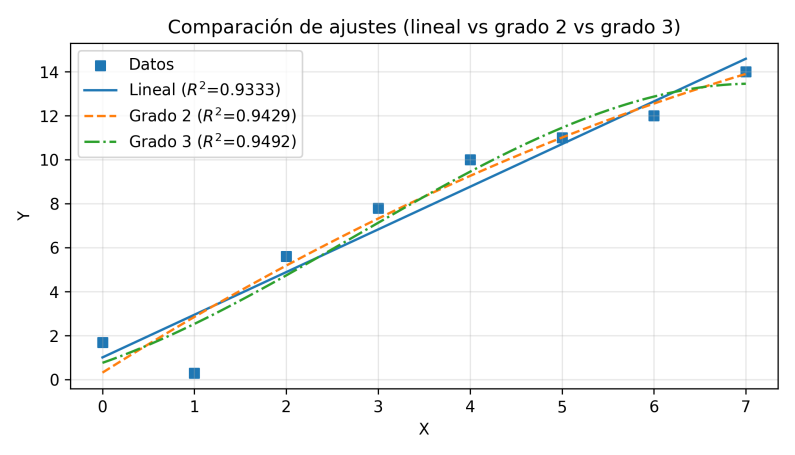

# $R^2$ en regresión lineal: cálculo manual paso a paso

## 1) Modelo lineal y predicción

Se ajusta el modelo:

$$\hat{y} = a_0 + a_1 x$$

y para cada dato $(x_i, y_i)$ se calcula la predicción:

$$\hat{y}_i = a_0 + a_1 x_i.$$

## 2) Promedio de los datos

Calcular el promedio de la variable dependiente:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i.$$

## 3) Suma de cuadrados total (SST)

Mide la variabilidad total de los datos respecto a su promedio:

$$SST = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

## 4) Suma de cuadrados del error (SSE)

Mide el error del modelo:

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} [y_i - (a_0 + a_1 x_i)]^2.$$

## 5) Coeficiente de determinación

Finalmente:

$$R^2 = 1 - \frac{SSE}{SST}.$$

# Ejercicio 1: Regresión lineal

## Datos

| $x$ | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| $y$ | 2 | 4 | 5 | 4 | 5 |

1. Ajustar un modelo lineal $P_1(x) = a_0 + a_1 x$.
2. Calcular las sumatorias necesarias.
3. Construir y resolver el sistema normal.
4. Calcular $SSE$ y el coeficiente $R^2$.

# Ejercicio 2: Regresión lineal

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| $y$ | 1 | 3 | 4 | 7 | 8 | 10 |

1. Ajustar $P_1(x) = a_0 + a_1 x$.
2. Determinar la ecuación de la recta.
3. Calcular $R^2$.

# Ejercicio 3: Regresión cuadrática

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 |
|---|---|---|---|---|---|
| $y$ | 2 | 3 | 7 | 13 | 21 |

1. Ajustar un polinomio cuadrático

$$P_2(x) = a_0 + a_1 x + a_2 x^2$$

2. Construir el sistema normal.
3. Resolver los coeficientes.
4. Calcular $R^2$.

# Ejercicio 4: Regresión cuadrática

## Datos

| $x$ | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| $y$ | 2,1 | 3,9 | 7,2 | 12,1 | 18,2 | 25,3 |

1. Ajustar $P_2(x)$.
2. Determinar el polinomio aproximante.
3. Calcular el coeficiente $R^2$.

# Ejercicio 5: Regresión cúbica

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| $y$ | 1 | 2 | 5 | 10 | 17 | 26 |

1. Ajustar un polinomio cúbico

$$P_3(x) = a_0 + a_1 x + a_2 x^2 + a_3 x^3$$

2. Construir el sistema normal.
3. Calcular los coeficientes.
4. Determinar $R^2$.

# Ejercicio 6: Regresión cúbica

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|---|
| $y$ | 1 | 4 | 9 | 15 | 23 | 34 | 48 |

1. Ajustar $P_3(x)$.
2. Determinar el polinomio.
3. Calcular $R^2$.

# Ejercicio 7: Comparación de modelos

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| $y$ | 2 | 2,5 | 3,5 | 6 | 9 | 13 |

1. Ajustar un modelo lineal.
2. Ajustar un modelo cuadrático.
3. Calcular $R^2$ en ambos casos.
4. Determinar cuál modelo describe mejor los datos.

# Ejercicio 8: Comparación de modelos

## Datos

| $x$ | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| $y$ | 1 | 3 | 6 | 11 | 18 | 27 |

1. Ajustar un modelo lineal.
2. Ajustar un modelo cuadrático.
3. Ajustar un modelo cúbico.
4. Calcular $R^2$ para cada caso.
5. Comparar los resultados.

# Ejercicio 9: Regresión cuártica

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|---|
| $y$ | 1 | 3 | 9 | 19 | 33 | 51 | 73 |

1. Ajustar un polinomio de grado 4:

$$P_4(x) = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + a_4 x^4$$

2. Construir el sistema normal.
3. Resolver los coeficientes.
4. Calcular $R^2$.

# Ejercicio 10: Análisis completo

## Datos

| $x$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 |
|---|---|---|---|---|---|---|---|---|
| $y$ | 1 | 2 | 4 | 7 | 11 | 16 | 22 | 29 |

1. Ajustar modelos:
   - lineal
   - cuadrático
   - cúbico
2. Calcular $R^2$ en cada caso.
3. Comparar los modelos.
4. Determinar cuál representa mejor los datos.

# Aplicación 1: Calibración de caudal en un canal (Q–h)

## Contexto físico

En un canal aforador, se mide el **tirante** $h$ (m) y el **caudal** $Q$ ($m^3/s$). Se desea obtener una ecuación de calibración para estimar $Q$ a partir de $h$.

## Datos experimentales

| $h$ (m) | 0,20 | 0,40 | 0,60 | 0,80 | 1,00 | 1,20 |
|---|---|---|---|---|---|---|
| $Q$ ($m^3/s$) | 0,028 | 0,072 | 0,138 | 0,226 | 0,336 | 0,468 |

## Tareas

1. Ajustar un modelo **cuadrático** $Q(h) = a_0 + a_1 h + a_2 h^2$ y calcular $R^2$.
2. Ajustar un modelo **cúbico** $Q(h) = a_0 + a_1 h + a_2 h^2 + a_3 h^3$ y calcular $R^2$.
3. Comparar los modelos y justificar cuál es más apropiado físicamente para el rango de $h$.
4. Usar el modelo elegido para estimar $Q$ cuando $h = 0{,}90$ m.

## Contexto físico

En un ensayo de tracción, se mide la **deformación unitaria** $\varepsilon$ (adimensional) y el **esfuerzo** $\sigma$ (MPa). En el rango elástico, se espera una relación aproximadamente lineal:

$$\sigma \approx E\,\varepsilon$$

donde $E$ es el **módulo de elasticidad**. Para facilitar el ajuste numérico, se define la variable reescalada:

$$x = 1000\,\varepsilon$$

## Datos reescalados

| $x = 1000\,\varepsilon$ | 0,2 | 0,4 | 0,6 | 0,8 | 1,0 | 1,2 |
|---|---|---|---|---|---|---|
| $\sigma$ (MPa) | 40 | 85 | 125 | 170 | 215 | 255 |

## Tareas

1. Ajustar un modelo **lineal**
$$\sigma(x) = a_0 + a_1 x$$
y calcular $R^2$.
2. Interpretar físicamente $a_0$ y $a_1$:
   - $a_0$ idealmente debería ser cercano a 0 (si no hay sesgo instrumental).
   - Como $x = 1000\,\varepsilon$, entonces:

# Aplicación 3: Curva de compactación (humedad–densidad seca)

## Contexto físico

En laboratorio se determina la curva de compactación: relación entre la **humedad** $w$ (%) y la **densidad seca** $\rho_d$ (g/cm$^3$ o Mg/m$^3$). La curva suele tener forma de "campana", por lo que un ajuste cuadrático es razonable en el rango de interés.

## Datos de compactación

| $w$ (%) | 8 | 10 | 12 | 14 | 16 | 18 |
|---|---|---|---|---|---|---|
| $\rho_d$ (Mg/m$^3$) | 1,72 | 1,80 | 1,86 | 1,84 | 1,79 | 1,70 |

## Tareas

1. Ajustar un modelo **cuadrático** $\rho_d(w) = a_0 + a_1 w + a_2 w^2$ y calcular $R^2$.
2. A partir del modelo, estimar:
   - **Humedad óptima** $w_{\text{opt}}$ (máximo de la parábola).
   - **Densidad seca máxima** $\rho_{d,\text{máx}}$.
3. Ajustar un modelo **cúbico** y comparar con el cuadrático usando $R^2$. ¿Cuál modelo es más consistente con el fenómeno físico?

# Código Python: ingreso de datos

```
import numpy as np
import matplotlib.pyplot as plt

print("AJUSTE POR MÍNIMOS CUADRADOS")

# número de puntos
n = int(input("Número de datos n = "))

x = np.zeros(n)
y = np.zeros(n)

for i in range(n):
    x[i] = float(input(f"x[{i}] = "))
    y[i] = float(input(f"y[{i}] = "))
```

# Código Python: seleccionar grado del polinomio

```
# grado del polinomio
m = int(input("Grado del polinomio m = "))

# construir matriz de diseño
X = np.vstack([x**k for k in range(m+1)]).T

# resolver por mínimos cuadrados
a, *_ = np.linalg.lstsq(X, y, rcond=None)

print("Coeficientes del polinomio:")
print(a)
```

# Código Python: cálculo de $R^2$

```
# predicción
y_hat = X @ a

# SSE
SSE = np.sum((y - y_hat)**2)

# promedio
y_bar = np.mean(y)

# SST
SST = np.sum((y - y_bar)**2)

# coeficiente de determinación
R2 = 1 - SSE/SST

print("SSE =", SSE)
print("R^2 =", R2)
```

# Código Python: gráfica del ajuste

```
# generar puntos para la curva
xx = np.linspace(x.min(), x.max(), 400)

# evaluar polinomio
yy = sum(a[k]*xx**k for k in range(len(a)))

plt.figure()
plt.scatter(x, y, marker="s", label="Datos")
plt.plot(xx, yy, label="Ajuste polinomial")

plt.xlabel("x")
plt.ylabel("y")
plt.title("Regresión por mínimos cuadrados")
plt.legend()
plt.grid(True)

plt.show()
```